RELATÓRIO DE PESQUISA | 29 OUT 2026

MIRA-Raul

Análise parcial do estudo

Da comparação entre modelos à investigação diagnóstica com supervisão

Autor: Raul Lima Capelo

Documento elaborado antes da finalização do projeto. Consolida resultados de desenvolvimento, auditorias e prioridades de validação.

Estado da evidência: avaliação exploratória com pacientes simulados e juízes LLM. Revisão médica independente pendente. Os resultados apresentados não estabelecem segurança clínica ou desempenho em uso assistencial.

O que o projeto procura responder

Um agente consegue colher uma história útil, selecionar exames, interpretar os resultados e formular um diagnóstico com custo e tempo controlados? O MIRA-Raul testa essa pergunta em casos publicados e em diferentes configurações de modelos e revisão.

O que já se observa

- A supervisão contribui para o resultado final; a proposta inicial do médico deve ser medida separadamente.
- A arquitetura ficou mais rápida e passou a registrar melhor a origem dos fatos e as limitações dos exames.
- A entrevista permanece uma frente de melhoria: mais turnos não significam, por si, mais informação clínica.

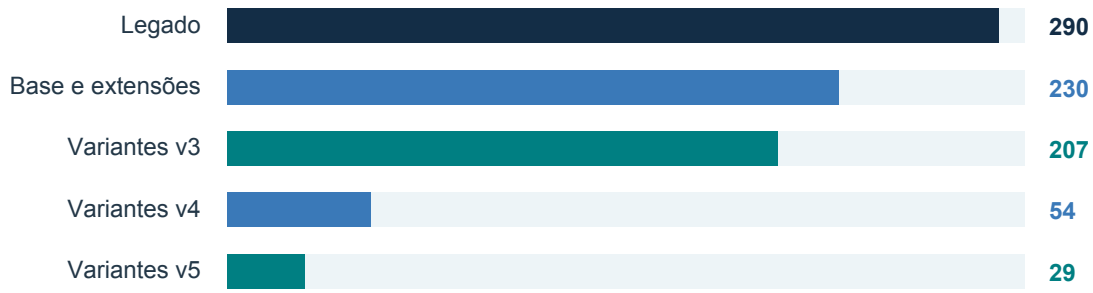
Referência temporal. A última versão publicada confirmada em 29/10 é a v5, integrada em 10/10/2026. Os agregados históricos usados aqui foram consolidados em 16/10; a auditoria longitudinal de anamnese foi concluída em 17/10. Não foram realizados novos encontros para este relatório.

01 | TRAJETÓRIA

Como o estudo evoluiu

Etapa	Mudança central e aprendizado
Legado / setembro	Ferramentas de consulta ao caso e comparação de modelos locais e de maior capacidade. Coleta predominantemente instrumental.
Rodada base / v1-v2	Paciente LLM, exames, diagnóstico final, controle de custos e três repetições dos dez casos.
v3 e cascatas	Entrevista mínima, exame inicial e revisão por outros agentes. O resultado final passa a depender também da supervisão.
v3.5-v3.7	Políticas mais estritas de exames, organização do prontuário e da fala; auditorias mostram que cobertura e fidelidade são dimensões diferentes.
v4 / Fast4	Conversa rápida com Flash-Lite; Sol e Astra revisam. Redução importante de tempo frente à v4 anterior.
v5	Justificativa de exames, urgência provisória, paciente com identificação de fatos e proteções contra repetição e estagnação.

Figura 1. Volume do histórico consolidado



810 registros terminais no inventário. Há repetição extensa de casos, modelos e condições. Não são 810 pacientes distintos, nem um denominador para uma taxa global. O inventário exclui pilotos legados fora do painel e análises offline sem novo encontro. Fonte: consolidação histórica [1].

02 | PRIMEIRA COMPARAÇÃO

O ponto de partida entre modelos

Cinco modelos, dez casos e três repetições: 150 encontros terminais. O resultado abaixo é a aceitação diagnóstica pelo juiz LLM entre os encontros julgados.

Figura 2. Juízos positivos na rodada base



Comprimento das barras: percentual de juízos positivos entre julgados (escala 0 a 100%). Rótulos: positivos/julgados. Fonte: três repetições [2].

Medida	Resultado
Encontros encerrados	150/150
Juízos positivos	91/144 julgados (63,2%)
Sem julgamento	6: cinco GPT-OSS e um GLM-4.5-Air
Custo global da fase	US$ 4,2742, incluindo pilotos e interrupções

Como interpretar

As repetições do mesmo caso são dependentes: a unidade clínica continua sendo o caso, não cada execução. Os resultados descrevem esta condição experimental e não estabelecem superioridade clínica entre modelos.

No legado, houve 290 registros terminais, 223 conclusões do fluxo e 112 correspondências lexicais. A métrica lexical é diferente do juiz LLM e não deve ser usada como uma linha de base numérica diretamente comparável.

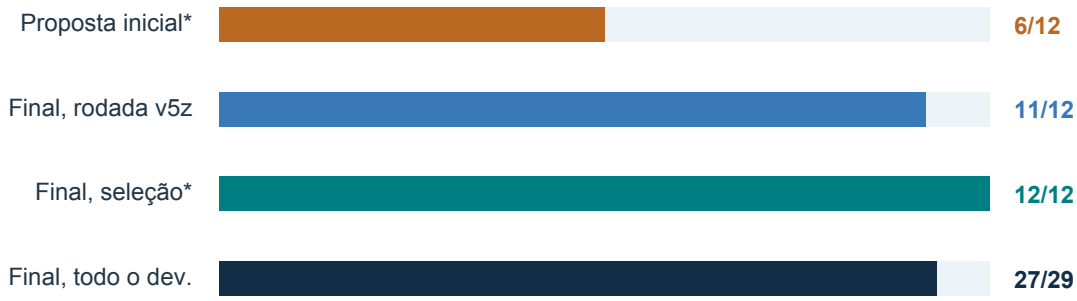
As extensões Qwen e Claude ampliaram o histórico. Alguns braços obtiveram resultados altos, mas com diferenças de transporte, critérios e pouca conversa com o paciente em determinadas configurações.

03 | SUPERVISÃO E V5

Proposta inicial e resultado final

A arquitetura atual combina o médico conversacional com revisores. Sua contribuição precisa permanecer visível nos resultados.

Figura 3. Resultados v5 em recortes diferentes



Escala: 0 a 100% de aceitação pelo juiz. *Proposta inicial e seleção final referem-se aos mesmos 12 casos selecionados. Os outros recortes têm condições ou execuções diferentes. Fontes: [1, 3].

12/12 não significa acurácia clínica de 100%. O agregado selecionado inclui correções e escolha de execuções. A rodada conjunta preservada foi 11/12. Nos 12 selecionados, o médico inicial teve 6/12 propostas aceitas. O ganho final pertence ao sistema com revisão, não ao médico isolado.

Operação: Fast4 versus v5

Medida nos 12 selecionados	Fast4	v5
Pedidos de investigação / caso	8,6	7,0
Primeiro resultado, mediana	10,4 s	9,3 s
Resultado final, mediana relatada	108 s	108 s
OpenRouter / caso	US$ 0,0268	US$ 0,0255

Na comparação histórica dos dez públicos, a mediana de tempo ativo da v4 anterior foi aproximadamente 516 s, contra 104 s na Fast4. A primeira fala completa da Fast4 ocorreu em cerca de 1,6 s. Mudaram modelos, contextos e transportes: não é um experimento que isola uma única causa.

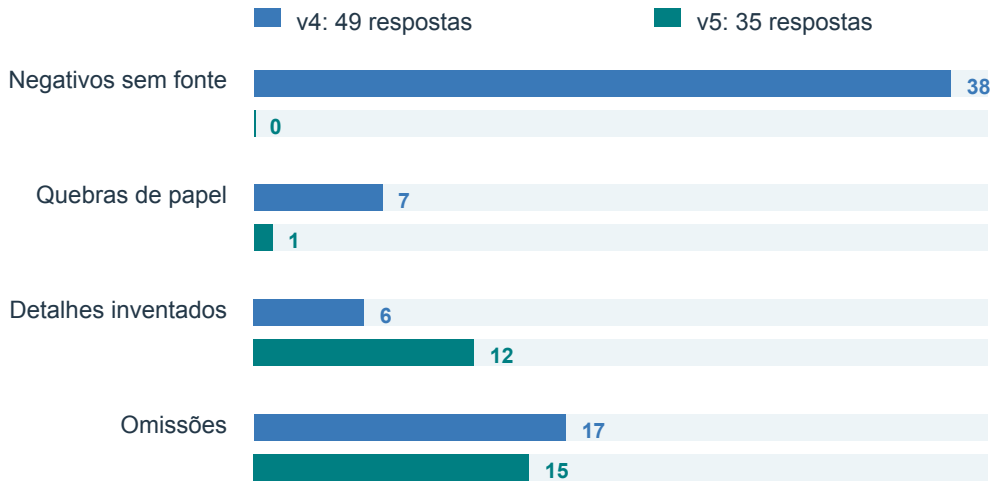
O gasto OpenRouter não inclui um custo monetário atribuível às assinaturas. Pedidos de investigação também não equivalem ao número de exames efetivamente executados ou ao custo de exames clínicos reais.

04 | PACIENTE E INFORMAÇÃO

O que melhorou na fidelidade

A v5 utiliza paciente Sonnet com resposta estruturada, identificação de fatos e validação. Isso aumenta a rastreabilidade, mas não elimina omissões e invenções.

Figura 4. Ocorrências na auditoria de respostas



Barras mostram **contagens de ocorrências**, não percentuais de respostas. As amostras têm tamanhos distintos. A auditoria foi feita por LLM da mesma família do paciente, sem adjudicação médica. Não usar a figura para estimar uma taxa geral de erro. Fonte: relatório v5 [3].

Ganhos e limites

Nesta amostra, desapareceram os negativos sem fonte detectados e diminuíram as quebras de papel. Entretanto, detalhes inventados e omissões continuaram. A melhora é específica e não sustenta uma afirmação de fidelidade garantida.

A v5 também acrescentou justificativa para cada exame, notas sobre divergências entre pedido e resultado, regras provisórias de urgência e proteções contra laços. Algumas proteções tiveram pouca exposição ou não foram acionadas nos casos avaliados.

As regras de urgência foram elaboradas no desenvolvimento e permanecem pendentes de revisão médica. A qualidade do simulador e a adequação clínica da decisão são avaliações separadas.

05 | ANAMNESE

A informação precisa ser aproveitada

A auditoria histórica examinou 66 registros públicos em 21 grupos, desde os primeiros pilotos até a v5. A evolução da entrevista não foi linear.

O que apareceu ao longo das versões

• Perguntas pertinentes sobre cronologia, medicamentos e riscos já existiam no legado, mas a resposta em blocos não reproduzia uma conversa humana.

• Em fases posteriores, parte das trocas atendia regras de liberação de exames. Uma mensagem de plano não deve contar como nova coleta de história.

• Conteúdo com perguntas junto de chamadas de ferramenta podia não ser encaminhado ao paciente. Gerar, enviar, responder e incorporar são etapas distintas.

• Persistiram perguntas extensas, desconhecidos pouco esclarecidos e pouca confirmação da história pelo paciente.

Figura 5. Classificação exploratória de 12 encontros v5



Rubrica própria, aplicada por um avaliador IA: abertura, cronologia, contexto, integração, reparo e síntese. Não é escore clínico validado. Uma entrevista breve em urgência pode ser adequada. Fontes: [4, 5].

Propostas para a próxima etapa

1. Garantir entrega da pergunta e associação à resposta correta.
2. Dar espaço ao relato em situações estáveis e aprofundar uma lacuna por vez.
3. Distinguir confirmado, negado, desconhecido, não perguntado e contraditório.
4. Fazer o seguimento depender do que a resposta anterior mudou.
5. Confirmar uma síntese curta, preservando correções do paciente.

Os materiais AHRQ e a amostra de três consultas simuladas completas e quatro excertos brasileiros reais de enfermagem orientaram essas propostas. Elas ainda não foram implementadas ou avaliadas no MIRA-Raul. Fonte: [6].

06 | BALANÇO PARCIAL

O que falta antes da conclusão

Prioridades de validação

Congelar a condição experimental; reservar casos novos; realizar repetições; separar contribuição do médico, paciente e revisores; e obter revisão médica cega de diagnóstico, entrevista, urgência e manejo. Avaliar reparo de ambiguidades, uso de pistas, fidelidade da síntese e trocas sem ganho de informação.

Situação financeira histórica

Item da última consolidação local	Valor
Subtotal de três livros de custos	US$ 20,7124
Uso acumulado nos snapshots da conta	US$ 20,8433
Diferença ainda sem atribuição esclarecida	US$ 0,1309

Não houve consulta de saldo atual. O subtotal não inclui custo monetário atribuível às assinaturas nem equivale ao custo integral de produção. A diferença não foi reclassificada nem atribuída a um ator. Fonte: [1].

Conclusão parcial

O MIRA-Raul dispõe de um histórico experimental auditável e apresentou avanços de velocidade, supervisão e rastreabilidade. Os melhores resultados finais permanecem ligados a condições de desenvolvimento e revisão. Generalização, qualidade clínica e eficácia das melhorias de anamnese continuam em aberto.

Fontes e rastreabilidade

[1] Métricas históricas, consolidação de 16/10/2026. Arquivo no projeto: outputs/metrics_history_2026-10-16/relatorio.md

[2] Resultados de três repetições, 04/10/2026. Arquivo no projeto: reports/repetitions_summary.md

[3] Relatório v5 e resumo de desenvolvimento, 10/10/2026. Arquivo no projeto: .claude/worktrees/complete-remaining-100-cases-356596/reports/v5_dev_report.md

[4] Auditoria da anamnese, legado à v5, 17/10/2026. Arquivo no projeto: outputs/anamnese_history_2026-10-17/relatorio.md

[5] Rubrica e classificação de 12 encontros v5, 16/10/2026. Arquivo no projeto: outputs/anamnese_quality_v5_2026-10-16/relatorio.md

[6] Amostra de transcrições e propostas, 16/10/2026. Arquivo no projeto: outputs/anamnese_sample_2026-10-16/relatorio.md

Fontes externas: AHRQ - Calibrate Dx; AHRQ - participação do paciente; PriMock57. Estudo-base: DOI 10.1038/s41591-026-04609-x, conforme protocolo local.